

APOYO A LA DECISIÓN CLÍNICA · NO DIAGNÓSTICO
AUTOMÁTICO

Sistema de priorización clínica de riesgo oncológico

Herramienta de apoyo para ordenar pacientes según probabilidad de cáncer cuando la capacidad asistencial es limitada. No reemplaza el juicio médico: lo prioriza.



COHORTE	MODELO RECOMENDADO	AUDIENCIA
50.001 pacientes	HistGradientBoosting	Tribunal académico
Prevalencia 19,29 %	AUC 0,843 · F1 0,576	Dirección hospitalaria · Comité IA

EJEMPLO REAL DE PRIORIZACIÓN CLÍNICA			
Bandeja de pacientes · ordenados por riesgo			07 · 05 · 2026
PACIENTE	CATEGORÍA	PERFIL CLÍNICO	RIESGO
P-00001	Alto riesgo	77 años · Fumador · Diabetes, HTA, obesidad · BRCA1, KRAS, PIK3CA	0,93
P-00002	Alto riesgo	57 años · Fumador · Diabetes, HTA, obesidad, card. · TP53, KRAS	0,93
P-00003	Alto riesgo	63 años · Fumador · HTA, obesidad · BRCA1, TP53, KRAS	0,93
P-00004	Riesgo medio	68 años · Fumador · Diabetes, HTA, EPOC · EGFR	0,50
P-00005	Bajo riesgo	27 años · No fumador · Sin antecedentes relevantes · ALK	0,01

OBJETIVO DEL ESTUDIO

¿Pueden datos tabulares multimodales anticipar riesgo de cáncer y apoyar el cribado y la priorización clínica?

Variable objetivo binaria cancer sobre 50.001 pacientes y seis colecciones clínicas. Prevalencia del 19,29 % ($\approx$ 1:4): la accuracy no es métrica suficiente.



COLECCIONES DE DATOS INTEGRADAS

FUENTE	TIPO DE VARIABLES
Clínicos	Diagnóstico, comorbilidades, historial
Bioquímicos	Analítica de sangre, marcadores
Genéticos	Mutaciones (TP53, BRCA1, KRAS, EGFR...)
Hábitos	Fumador, actividad física
Sociodemográficos	Edad, zona, nivel educativo
Económicos	Tipo de seguro (no post-diagnóstico)

VARIABLES EXCLUIDAS · prevenir data leakage

coste_total	coste_farmaco
num_ingresos	dias_hospital
vive	paciente_id
cancer (target)	alcohol (constante)

Las variables posteriores al diagnóstico se excluyen para evitar leakage y rendimiento irreal. alcohol es constante y no aporta información.

VARIABLES INCLUIDAS EN EL MODELO

- Bioquímicas
- Comorbilidades
- Mutaciones genéticas
- Fumador
- Actividad física
- Edad
- Sociodemográficas

ENCUADRE CLÍNICO

El objetivo no es diagnosticar: es **identificar antes a los pacientes que deben revisarse primero**. Se evalúa con recall, F1, AUC-ROC y calibración, no con accuracy.

COMPARATIVA DE MODELOS CLÁSICOS

Cuatro familias de modelos sobre la misma matriz, sin leakage

Comparativa al **umbral por defecto 0,50** sobre el conjunto de test estratificado. La selección final del umbral (política equilibrada) se presenta en la slide siguiente.

MODELO	PRECISIÓN	RECALL	F1	AUC	ACC.
★ HistGradientBoosting	0,441	0,754	0,557	0,843	0,768
Logistic Regression	0,435	0,759	0,553	0,841	0,763
Extra Trees	0,577	0,502	0,537	0,831	0,833
Random Forest	0,676	0,361	0,471	0,835	0,843

IMPACTO DEL DESBALANCE · POR QUÉ LA ACCURACY NO APLICA

El desbalance (1:4) provoca que modelos con alta accuracy fallen en detectar casos positivos, lo que los hace clínicamente inadecuados. Random Forest acierta el 84,3 % global pero recupera solo el 36 % de los cánceres reales. Se optimiza **F1** como compromiso entre sensibilidad (recall) y carga asistencial (precisión).

MATRIZ DE CONFUSIÓN · HISTGRADIENTBOOSTING umbral 0,37 · alta sensibilidad ilustrativa

	PRED. NO CÁNCER	PRED. CÁNCER
REAL · NO CÁNCER	5.161	2.911
REAL · CÁNCER	272	1.657

85,9 % DE POSITIVOS RECUPERADOS · 272 FALSOS NEGATIVOS SOBRE 1.929

LECTURA CLÍNICA

El modelo recupera la mayoría de los casos de cáncer asumiendo falsos positivos aceptables en un contexto de cribado. Pierde brillo en métricas, gana defendibilidad: predice con información disponible antes del diagnóstico.

MÉTRICAS · HISTGRADIENTBOOSTING · umbral por defecto

Precisión		0,441
Recall		0,754
F1		0,557

El modelo detecta el 85,9 % de los casos positivos (alta sensibilidad), clave en contexto de cribado.

RED NEURONAL MULTICAPA PARA DATOS TABULARES

Más complejidad no se traduce en beneficio clínico

MLP regularizada sobre la misma matriz que ML. `class_weight`, `EarlyStopping` y `ReduceLRonPlateau` compensan el desbalance y el sobreajuste.

ARQUITECTURA

Dense 128 · BatchNorm · ReLU · Dropout 0,25

L1

Dense 64 · BatchNorm · ReLU · Dropout 0,25

L2

Dense 32 · BatchNorm · ReLU · Dropout 0,20

L3

Dense 1 · Sigmoid

out


CLASS_WEIGHT

EARLYSTOPPING

REDUCELRONPLATEAU

KERAS / TORCH

CURVAS DE ENTRENAMIENTO POR ÉPOCA



HEAD-TO-HEAD SOBRE TEST

MODELO	TH	PREC.	RECALL	F1	AUC	ACC.
MLP	0,32	0,522	0,630	0,571	0,840	0,817
★ HistGradientBoosting	0,65	0,552	0,602	0,576	0,843	0,829

Δ RECALL

+0,028

MLP recupera más positivos

Δ F1

-0,005

Diferencia no significativa

Δ AUC

-0,003

Empate técnico

LECTURA CLÍNICA

La MLP mejora ligeramente el recall, pero no supera al boosting en rendimiento global (F1, AUC). Más complejidad no se traduce en beneficio clínico significativo: la decisión es práctica, no técnica.

COMPARATIVA GLOBAL DE RENDIMIENTO

Empate técnico en rendimiento; el boosting gana en simplicidad operativa


Métricas en el conjunto de test al umbral óptimo de cada modelo. AUC casi idéntico; las diferencias en F1, recall y precisión son marginales.

	HISTGRADIENTBOOSTING		MLP	
Precisión		0,552		0,522
Recall		0,602		0,630
F1		0,576		0,571
AUC-ROC		0,843		0,840
Accuracy		0,829		0,817

RANKING FINAL

- 1. HistGradientBoosting · mejor balance F1/AUC y más simple
- 2. MLP · ligera ventaja en recall, más compleja
- 3. Logistic Regression · baseline lineal sólido
- 4. Extra Trees
- 5. Random Forest · alta accuracy, baja sensibilidad

CURVAS ROC Y ESPACIO PRECISIÓN-RECALL



En el espacio Precisión-Recall, el boosting mantiene mejor equilibrio, mientras la MLP mejora recall a costa de precisión. Se optimiza F1 como compromiso entre sensibilidad y carga asistencial.

RESUMEN COMPARATIVO

MODELO	F1	AUC	LECTURA
★ HistGradientBoosting	0,576	0,843	Equilibrio + simplicidad
MLP	0,571	0,840	Recall ligeramente superior
Logistic Regression	0,553	0,841	Baseline lineal sólido

SELECCIÓN DEL UMBRAL SEGÚN LA POLÍTICA CLÍNICA

Un modelo, tres puntos de operación clínicamente útiles

HistGradientBoosting expone una probabilidad continua. El umbral se elige según los recursos del centro y la tolerancia a falsos negativos.

TRES POLÍTICAS CLÍNICAS · MISMO MODELO, DISTINTOS PUNTOS DE OPERACIÓN

Cribado sensible

umbral bajo

Maximiza el recall. Detecta el máximo de positivos a costa de más falsos positivos. Apto cuando el coste de perder un caso es muy alto y hay capacidad de revisión.

★ RECOMENDADO

Priorización equilibrada

umbral 0,65

F1
0,576

RECALL
0,602

PRECISIÓN
0,552


Compromiso entre sensibilidad y carga asistencial. Punto de partida del piloto clínico.

Alta precisión

umbral alto

Minimiza falsos positivos: alertas más confiables a costa de más falsos negativos. Apto para unidades con capacidad limitada o pruebas confirmatorias caras.

DECISION CURVE ANALYSIS



El beneficio clínico neto supera a las estrategias *treat-all* y *treat-none* en el rango de umbrales clínicamente relevantes.

El umbral se elige por política clínica, no por accuracy. Se optimiza F1 como compromiso entre sensibilidad (recall) y carga asistencial (precisión).

¿Son los datos suficientemente buenos para anticipar cáncer?

DECISIÓN

Sí, para **priorización clínica**.
No, para diagnóstico automático.

Implantar **HistGradientBoosting**: mejor equilibrio entre F1, AUC y simplicidad operativa, con umbral ajustable según la política del centro.

El sistema permite reducir retrasos diagnósticos priorizando pacientes de alto riesgo dentro de la capacidad asistencial existente.

IMPACTO OPERATIVO · POLÍTICA DE PRIORIZACIÓN · POR 1.000 PACIENTES

210
ALERTAS TOTALES

117
CASOS DETECTADOS

93
FALSOS POSITIVOS

76
FALSOS NEGATIVOS

ROADMAP DE VALIDACIÓN CLÍNICA

01	02	03	04	05	06
Validación retrospectiva real	Validación temporal con fechas reales	Validación externa en otro centro	Estudio prospectivo silencioso	Piloto clínico supervisado	Despliegue limitado con monitorización

PROPUESTA DE VALOR EMPRESARIAL

COMPRADOR	Hospital · atención primaria · aseguradora
DOLOR QUE RESUELVE	Listas de espera · retrasos diagnósticos · priorización de pruebas
KPI DE NEGOCIO	Tiempo hasta revisión · coste por caso detectado · falsos negativos evitables

LIMITACIONES

- Dataset sintético
- Sin validación externa ni temporal
- Posible sesgo por subgrupos
- Requiere supervisión médica

DATOS QUE MEJORARÍAN PREDICCIÓN

- Fechas clínicas reales
- Síntomas y antecedentes familiares
- Imagen médica
- Biomarcadores y evolución temporal

GOBERNANZA · RGPD Y ÉTICA

Software de **apoyo a la decisión clínica**, no diagnóstico autónomo. Trazabilidad completa por alerta, explicabilidad para el clínico, minimización de datos y protocolo de fallo seguro.

No sustituye al médico.

Ordena pacientes cuando la capacidad asistencial es limitada.

“Viable como herramienta de priorización clínica bajo supervisión médica y validación externa; **no como diagnóstico automático.**”

MODELO RECOMENDADO

- HistGradientBoosting con política equilibrada.
- AUC 0,843 · F1 0,576
 - Recall 0,602 · Precisión 0,552
 - Umbral 0,65 · política equilibrada
 - Versión alternativa sin genética disponible

VALOR PARA LA ORGANIZACIÓN

- Menos retrasos diagnósticos
- Mejor uso del tiempo de especialistas
- Carga asistencial dimensionable
- Trazabilidad y auditoría por alerta
- ROI conceptual positivo a validar en piloto

PRÓXIMOS PASOS

- Validación retrospectiva en cohorte real
- Piloto clínico supervisado · 1 unidad
- Comité de IA sanitaria + RGPD
- Métricas de impacto operativo
- Decisión informada de despliegue